DETEKSI SERANGAN MALWARE PADA JARINGAN INTERNET OF THINGS MENGGUNAKAN ALGORITMA DECISION TREE DENGAN TEKNIK SELEKSI FITUR DAN OPTIMASI PARAMETER

PROPOSAL TUGAS AKHIR

Oleh:

Belinda Panjaitan

4332101022

Disusun untuk pengajuan proposal Tugas Akhir Program Diploma IV

PROGRAM STUDI REKAYASA KEAMANAN SIBER

JURUSAN TEKNIK INFORMATIKA

POLITEKNIK NEGERI BATAM

2024

DAFTAR ISI

DAFTAR ISI 2

DAFTAR GAMBAR 3

DAFTAR TABEL 3

BAB I PENDAHULUAN 4

1. Latar Belakang 4
2. Rumusan Masalah 5
3. Tujuan 5

BAB II LANDASAN TEORI 6

1. *Internet of Things* 6
2. Serangan Malware pada IoT 7
3. Pengembangan Model Deteksi Serangan Berbasis *Machine Learning* 8
4. *Decision Tree* 10
5. Teknik Seleksi Fitur 11
6. Teknik Optimasi Parameter 12
7. *Scikit-Learn* 13

BAB III METODE PENELITIAN 14

1. Alur Penelitian 14
2. Dataset Penelitian 15
3. Pembersihan Data 16
4. Parameter-Parameter pada Algoritma *Decision Tree* 16
5. Evaluasi 16

DAFTAR PUSTAKA 18

DAFTAR GAMBAR

Gambar 2.1. Arsitektur Internet of Things [10] 7
Gambar 2.2. Perbedaan antara Program Biasa dengan Machine Learning 9
Gambar 2.3. Kerangka Kerja untuk Membangun Model Deteksi Serangan Malware 9
Gambar 2.4. Struktur Pohon pada Decision Tree [16] 11
Gambar 2.5. Teknik Optimasi Parameter Menggunakan GridSearchCV 13
Gambar 3.1. Alur Penelitian Deteksi Serangan Malware pada Jaringan IoT ……14

DAFTAR TABEL

Tabel 3.1. Jumlah Serangan pada Dataset CICIoT2023 15
Tabel 3.2. Confusion Matrix 16

BAB I
PENDAHULUAN

1. Latar Belakang

Saat ini, perkembangan internet telah banyak digunakan di berbagai perangkat, baik di perumahan, industri, pendidikan, dan sebagainya [1]. *Internet of Things* (IoT) merupakan suatu konsep dimana berbagai perangkat tersebut, seperti sensor, perangkat elektronik, dan objek fisik lainnya, dapat terhubung dan berkomunikasi melalui jaringan internet. Hal ini memberikan kemudahan dengan melakukan otomatisasi pekerjaan serta meningkatkan efisiensi dalam penggunaan sumber daya [2].

Peningkatan penggunaan IoT ini juga diikuti dengan peningkatan risiko terhadap serangan malware. Serangan malware pada perangkat IoT dapat mengganggu kinerja perangkat sehingga perangkat tidak dapat bekerja optimal dan bahkan dapat bekerja di luar kendali [3]. Hal ini dapat menyebabkan kerugian, baik secara finansial akibat terganggunya operasional maupun secara hukum jika terjadi kebocoran data. Salah satu jenis malware yang paling berbahaya dan sering terjadi pada jaringan IoT adalah Mirai [4]. Mirai dapat menginfeksi perangkat IoT dan mengubahnya menjadi botnet yang dapat melancarkan serangan siber dalam skala besar, seperti serangan DDoS (*Distributed Denial of Service*) [5]. Oleh karena itu, deteksi serangan malware, khususnya Mirai, pada jaringan IoT diperlukan untuk mencegah dan mengurangi kerugian.

Salah satu metode deteksi serangan malware pada jaringan IoT adalah dengan menggunakan algoritma *machine learning*, yaitu *Decision Tree* dan *Random Forest* [6]. Kedua algoritma tersebut menghasilkan nilai akurasi yang tinggi pada deteksi serangan malware, yaitu mencapai 99%. Kemudian, untuk meningkatkan kinerja algoritma *machine learning* yang digunakan dapat dilakukan teknik seleksi fitur dan optimasi parameter [7][8]. Seleksi fitur adalah proses untuk mengurangi dimensi data dengan memilih fitur-fitur yang relevan sehingga dapat meningkatkan kinerja algoritma *machine learning*. Sedangkan optimasi parameter digunakan untuk memilih nilai yang optimal dari parameter-parameter pada algoritma *machine learning* yang dapat menghasilkan kinerja yang paling baik.

Penelitian ini akan membangun model deteksi serangan malware pada jaringan IoT menggunakan algoritma *Decision Tree* dengan teknik seleksi fitur dan optimasi parameter. Algoritma *Decision Tree* dipilih karena kemudahan interpretasinya dan memiliki kemampuan

yang baik dalam model klasifikasi dengan nilai akurasi yang tinggi dan waktu yang cepat. Kemudian, teknik seleksi fitur yang digunakan adalah filter korelasi yang dapat mengurangi fitur-fitur dengan nilai korelasi yang tinggi yang memiliki hubungan secara linier. Sedangkan *GridSearchCV* digunakan sebagai teknik optimasi parameter karena dapat mencari kombinasi nilai dari parameter-parameter pada algoritma *Decision Tree* secara paralel yang dapat menghasilkan kinerja yang paling baik.

2. Rumusan Masalah

Rumusan permasalahan pada penelitian ini adalah sebagai berikut.

1) Bagaimana membangun model deteksi serangan malware pada jaringan IoT menggunakan algoritma *Decision Tree* dengan filter korelasi sebagai teknik seleksi fitur dan *GridSearchCV* sebagai teknik optimasi parameter?
2) Bagaimana evaluasi kinerja model deteksi serangan malware pada jaringan IoT menggunakan algoritma *Decision Tree* dengan filter korelasi sebagai teknik seleksi fitur dan *GridSearchCV* sebagai teknik optimasi parameter?

3. Tujuan

Tujuan pada penelitian ini adalah sebagai berikut.

1) Pengembangan model deteksi serangan malware pada jaringan IoT menggunakan algoritma *Decision Tree* dengan filter korelasi sebagai teknik seleksi fitur dan *GridSearchCV* sebagai teknik optimasi parameter.
2) Peningkatan kinerja deteksi serangan malware pada jaringan IoT menggunakan algoritma *Decision Tree* dengan filter korelasi sebagai teknik seleksi fitur dan *GridSearchCV* sebagai teknik optimasi parameter.

BAB II
LANDASAN TEORI

1. *Internet of Things*

Internet of Things (IoT) merupakan perangkat-perangkat fisik yang terhubung dengan internet sehingga dapat mengumpulkan, mengirimkan, dan menganalisis data [9]. Perangkat ini mencakup berbagai hal, mulai dari sensor pada peralatan rumah tangga hingga kendaraan dan mesin-mesin pada dunia industri. Dengan konektivitas internet, perangkat-perangkat ini dapat berkomunikasi satu sama lain bahkan pada sistem yang lebih besar, dapat memberikan kemampuan untuk mengotomasi dan mengoptimalkan berbagai proses. Arsitektur pada perangkat IoT digambarkan pada Gambar 2.1. dengan beberapa komponennya yaitu sebagai berikut.

1) Sensor

   Sensor berfungsi untuk mengambil data dari lingkungan atau objek perangkat, seperti suhu dan kelembaban pada termostat, cahaya dan gerakan pada kamera CCTV, dan lain sebagainya.

2) Konektivitas

   Perangkat IoT terhubung ke internet melalui berbagai teknologi komunikasi, seperti Wi-Fi, Bluetooth, dan lain sebagainya, untuk mengirim dan menerima data secara *real-time*.

3) Platform *Cloud*

   Data yang diambil oleh perangkat IoT dapat dikirim ke platform *cloud* untuk diproses dan dianalisis sehingga dapat menghasilkan informasi yang lebih berguna, terutama untuk pengambilan keputusan.

4) Antarmuka Pengguna

   Pengguna dapat mengakses perangkat IoT melalui antarmuka pengguna, seperti aplikasi *mobile* atau *website*, untuk memantau dan mengatur perangkat IoT sesuai kebutuhan.

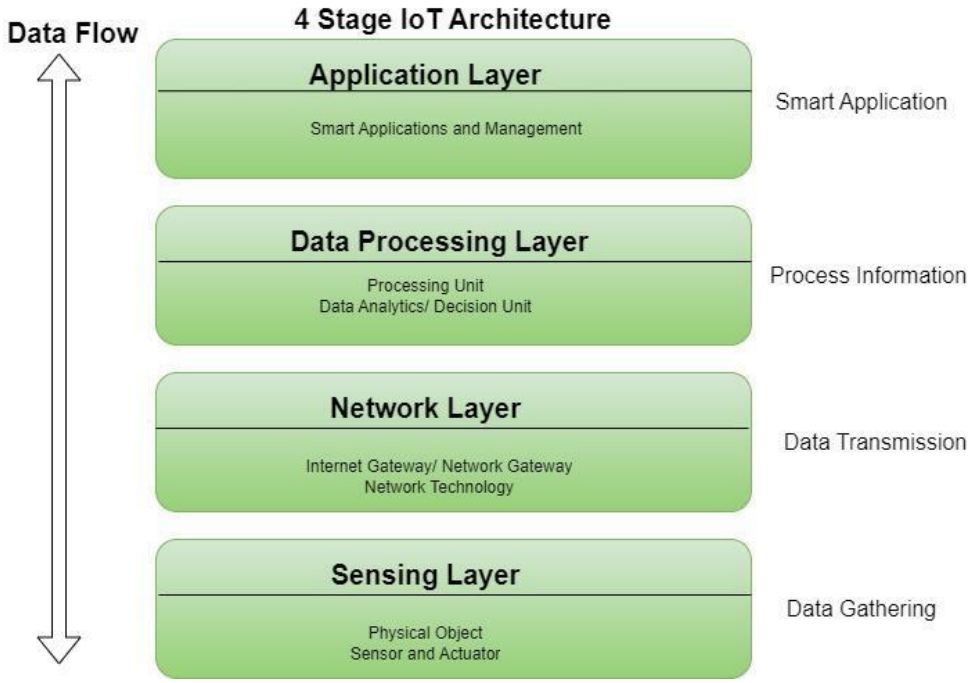

Gambar 2.1. Arsitektur Internet of Things [10]

2. Serangan Malware pada IoT

Malware atau malicious software merupakan program komputer berbahaya yang dirancang untuk menyusup, merusak, mengubah, atau mencuri data dari sistem informasi komputer, atau jaringan target [11]. Malware dapat menyebabkan berbagai masalah yang dapat mempengaruhi kerahasiaan, integritas, dan ketersediaan data. Serangan malware pada IoT merujuk pada berbagai bentuk serangan malware yang ditujukan terhadap perangkat yang terhubung ke jaringan IoT. Semakin banyak perangkat yang terhubung tersebut, risiko serangan malware juga meningkat. Jenis-jenis serangan siber pada IoT yaitu sebagai berikut.

1) DDoS (*Distributed Denial of Service*)

DDoS merupakan serangan yang dilakukan dengan membanjiri (*flooding*) server atau jaringan target dengan banyak trafik yang melebihi dari kemampuannya sehingga layanan menjadi *overload* dan tidak tersedia. Serangan ini biasanya memanfaatkan sejumlah perangkat yang terinfeksi menjadi botnet atau suatu malware bernama Mirai.

2) *Man-in-the-Middle* (MitM)

MitM merupakan serangan yang dilakukan dengan menyusup ke jalur komunikasi antara perangkat IoT dengan server atau perangkat IoT lainnya. Serangan ini dapat membaca, mengubah, dan menyalin data bahkan mengambil alih perangkat secara tidak sah.

3) *Injection*

Injection merupakan serangan yang dilakukan dengan menyisipkan kode berbahaya ke dalam aplikasi pada perangkat IoT. Contoh serangan ini adalah SQL *injection* yang dapat digunakan untuk mengakses basis data atau mengambil alih perangkat.

4) *Spoofing*

Spoofing merupakan serangan yang dilakukan dengan menipu atau menyamar dengan tujuan untuk mendapatkan akses yang tidak sah dan mencuri informasi. Jenis-jenis serangan ini yaitu IP *spoofing*, email *spoofing*, URL *spoofing*, dan DNS *spoofing*.

5) *Reconnaissance*

Reconnaissance atau pengintaian merupakan serangan yang dilakukan dengan mengumpulkan informasi-informasi sistem dan jaringan target. Serangan ini dapat berupa OS scan, port scan, vulnerability scan, dan sebagainya.

6) *Brute Force*

Brute Force merupakan serangan dengan mencoba semua kemungkinan kombinasi kata sandi secara sistematis untuk menemukan kredensial pengguna yang sesuai.

3. Pengembangan Model Deteksi Serangan Berbasis *Machine Learning*

Machine Learning (ML) adalah bagian dari *Artificial Intelligence* (AI) atau kecerdasan buatan yang merupakan suatu mesin atau komputer yang dapat mempelajari data tanpa diprogram secara khusus [12]. Tidak seperti program komputer pada umumnya yang bergantung pada instruksi manusia (*programmer*), mesin atau komputer ini mampu mengidentifikasi pola, membuat prediksi, dan mengambil keputusan secara mandiri berdasarkan data yang diberikan. Gambar 2.2. menampilkan perbedaan antara program komputer biasa dengan *machine learning* [13].

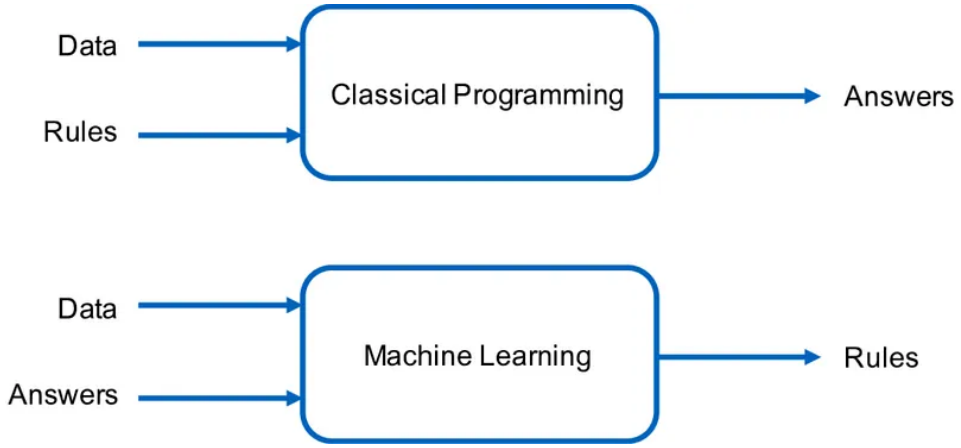

Gambar 2.2. Perbedaan antara Program Biasa dengan Machine Learning

Untuk membangun model deteksi serangan malware, digunakan suatu kerangka kerja seperti yang ditampilkan pada Gambar 2.3. sebagai berikut [14].

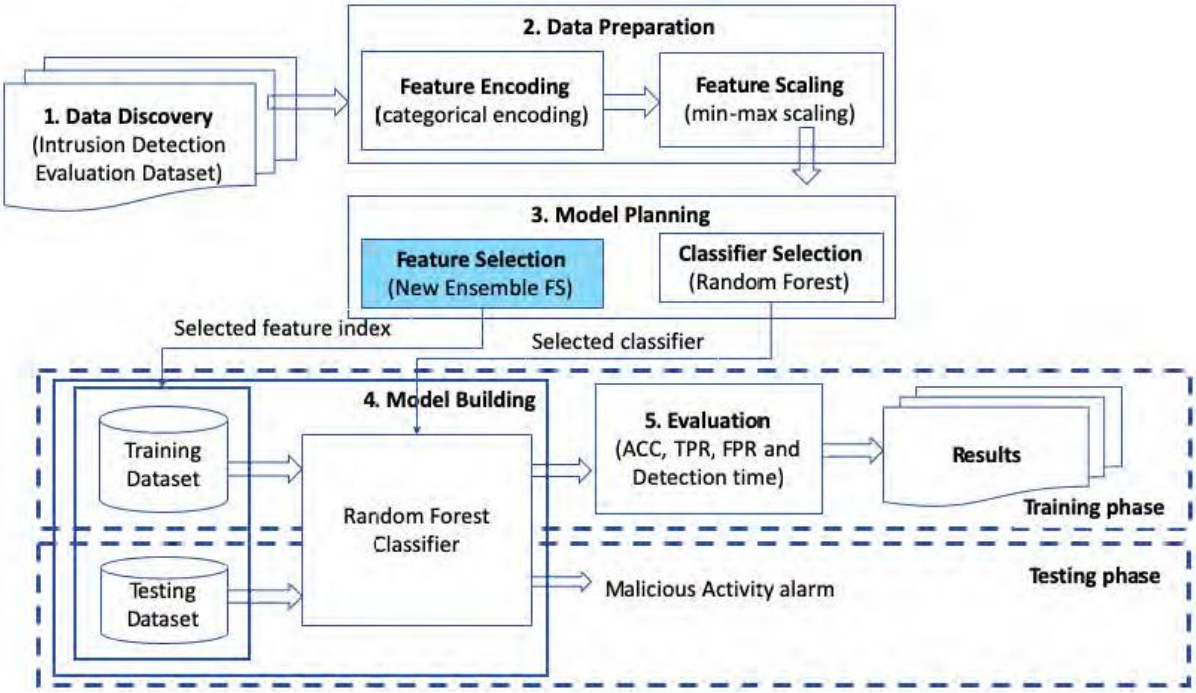

Gambar 2.3. Kerangka Kerja untuk Membangun Model Deteksi Serangan Malware

Berdasarkan Gambar 2.3., tahapan-tahapan untuk membangun model deteksi serangan malware yaitu:

1) Ekplorasi Data, yang meliputi identifikasi informasi apa saja yang dapat digunakan, seperti jumlah data, fitur data, tipe data, dan sebagainya.

2) Persiapan Data, yang meliputi transformasi dari data non-numerik menjadi data numerik, kodefikasi label, menangani nilai kosong atau invalid, normalisasi data, penyeimbangan data, dan sebagainya.
3) Perencanaan Model, yang meliputi pemilihan algoritma machine learning yang akan digunakan, seleksi fitur untuk memilih fitur-fitur yang relevan, dan optimasi parameter untuk memilih parameter-parameter yang optimal.
4) Perencanaan Model, yang meliputi pelatihan dan pengujian algoritma dan model-model yang terkait menggunakan data yang telah disiapkan.
5) Evaluasi, yang meliputi pengukuran kinerja model yang dibangun, seperti akurasi, presisi, *recall*, F1, dan waktu komputasi.

4. *Decision Tree*

Decision Tree adalah algoritma *machine learning* yang memiliki struktur mirip sebuah pohon, yaitu terdiri dari akar, ranting, dan daun [15]. Algoritma ini dapat digunakan untuk kasus klasifikasi dan regresi. Contoh struktur pohon pada algoritma ini ditunjukkan pada Gambar 2.4. Setiap akar atau *node* mewakili fitur pada dataset, setiap ranting atau *branch* mewakili aturan keputusan (*decision rule*) berdasarkan nilai fitur, dan setiap daun (*leaf*) mewakili hasil akhir atau kelas yang diprediksi. Cara kerja *Decision Tree* yaitu sebagai berikut [16].

1) Pemilihan Fitur

   Dataset yang terdiri dari fitur-fitur (atribut) dan label (target) dibagi berdasarkan fitur yang paling informatif. Pemilihan fitur ini dilakukan dengan menggunakan kriteria tertentu, seperti *gini* dan *entropy*.
2) Pembentukan Pohon

   Setelah fitur dipilih, node baru dibentuk untuk setiap kelompok. Proses ini dilakukan secara berulang untuk setiap node baru hingga:
   - semua data di dalam node memiliki label yang sama,
   - tidak ada fitur yang tersisa, dan
   - tingkat kedalaman tree mencapai batas yang telah ditentukan.
3) *Prunning* (Pemangkasan)

Setelah model selesai dibangun, model ini dapat dipangkas (*pruned*) dengan menghapus beberapa node yang tidak memberikan informasi tambahan yang signifikan. Hal ini bertujuan untuk menghindari *overfiting*.

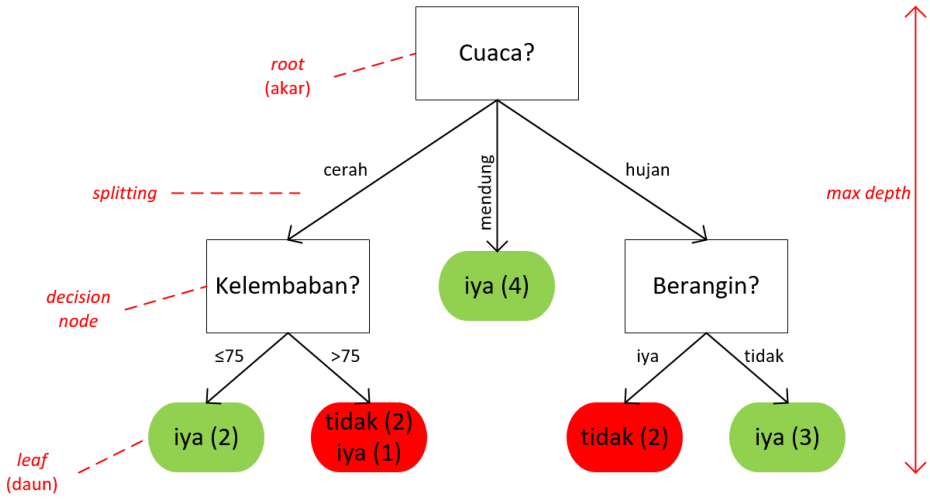

Gambar 2.4. Struktur Pohon pada Decision Tree [16]

5. Teknik Seleksi Fitur

Teknik seleksi fitur adalah proses pengurangan atau penurunan dimensi data dengan memilih beberapa fitur tertentu melalui suatu metode tertentu [17]. Tujuan utama dari teknik ini adalah untuk meningkatkan kinerja suatu algoritma *machine learning* dengan hanya melatih beberapa fitur yang relevan. Selain itu, teknik ini juga dapat mengurangi penggunaan sumber daya yang mengakibatkan waktu komputasi yang lebih cepat. Secara garis besar, terdapat 3 metode seleksi fitur, yaitu sebagai berikut [18].

1) metode filter yang menggunakan ilmu statistik, seperti nilai varians, nilai korelasi, nilai mutual informasi, dan sebagainya;
2) metode wrapper yang menggunakan evaluasi kombinasi fitur pada algoritma *machine learning*, seperti *random forest*, yang menghasilkan nilai akurasi yang terbaik; dan
3) metode tertanam (*embedded*) yang memilih fitur ketika proses pembelajaran sedang dilakukan, seperti regularisasi.

Filter korelasi merupakan salah satu metode filter yang paling sering digunakan pada kasus klasifikasi. Korelasi adalah ukuran hubungan antara dua variabel atau fitur yang

berbeda dimana nilainya berada pada rentang -1 hingga +1 [19]. Nilai -1 menunjukkan nilai korelasi negatif yang berarti terdapat hubungan berbanding terbalik yang sempurna antara kedua variabel. Sebaliknya, nilai +1 menunjukkan nilai korelasi positif yang berarti terdapat hubungan berbanding lurus yang sempurna antara kedua variabel. Sedangkan nilai 0 menunjukkan tidak terdapat hubungan antara kedua variabel tersebut. Persamaan untuk mendapatkan nilai korelasi adalah sebagai berikut.

$$\boldsymbol{r} = \frac{\sum(\boldsymbol{x} - \overline{\boldsymbol{x}})(\boldsymbol{y} - \overline{\boldsymbol{y}})}{\sqrt{\sum(\boldsymbol{x} - \overline{\boldsymbol{x}})^2 \sum(\boldsymbol{y} - \overline{\boldsymbol{y}})^2}}$$

keterangan:

$\boldsymbol{r}$ = nilai korelasi

$\boldsymbol{x}$ = nilai fitur ke-1

$\boldsymbol{y}$ = nilai fitur ke-2

$\overline{\boldsymbol{x}}$ = rata-rata nilai fitur ke-1

$\overline{\boldsymbol{y}}$ = rata-rata nilai fitur ke-2

Fitur-fitur yang memiliki korelasi tinggi, yaitu mendekati nilai -1 atau +1, tidak memberikan banyak informasi baru untuk model *machine learning* dan dapat menyebabkan multikolinearitas, yaitu kesalahan hasil prediksi akibat data yang berhubungan secara linier [20]. Oleh karena itu, filter korelasi digunakan untuk menghilangkan salah satu fitur dengan nilai korelasi yang tinggi.

6. Teknik Optimasi Parameter

Setiap algoritma pada *machine learning* memiliki beberapa parameter yang harus dikonfigurasi untuk mendapatkan hasil yang terbaik. Salah satu teknik untuk mendapatkan nilai yang optimal dari masing-masing parameter adalah dengan menggunakan *GridSearchCV*. *Grid Search* adalah proses untuk menemukan kombinasi parameter yang paling optimal dari suatu model klasifikasi dengan masing-masing parameter diberikan rentang nilai tertentu [21]. Sedangkan *Cross Validation* (CV) adalah proses validasi untuk menilai kinerja dari suatu model klasifikasi pada setiap bagian dataset yang independen [22]. Proses dari teknik optimasi parameter menggunakan GridSearchCV ditunjukkan pada Gambar 2.5.

Parameter	Parameter P Nilai ke-1 (P1)	Parameter 2 Nilai ke-2 (P2)
Parameter Q Nilai ke-1 (Q1)	(P1,Q1)	(P2,Q1)
Parameter Q Nilai ke-2 Q2	(P1,Q2)	(P2,Q2)

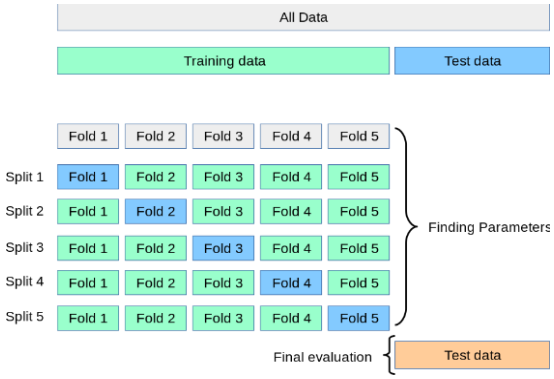

Gambar 2.5. Teknik Optimasi Parameter Menggunakan *GridSearchCV*

7. *Scikit-Learn*

Scikit-Learn adalah salah satu pustaka (*library*) pada pemrograman berbahasa python yang paling populer untuk *machine learning*. Pustaka ini menyediakan berbagai alat dan algoritma untuk analisis data, pemodelan, dan evaluasi model [23]. Beberapa fitur pada pustaka ini yaitu sebagai berikut.

1) *Machine Learning*, yaitu fitur yang menyediakan berbagai algoritma untuk *machine learning*, termasuk klasifikasi, regresi, dan klasterisasi, seperti *linear regression*, *decision tree*, *k-means*, dan sebagainya.
2) *Preprocessing Data*, yaitu fitur yang berfungsi untuk melakukan *preprocessing data*, seperti normalisasi, kodifikasi, pembagian dataset menjadi pelatihan dan pengujian, dan sebagainya.
3) Pemilihan dan Evaluasi Model, yaitu fitur yang berfungsi untuk melakukan pemilihan dan evaluasi model, seperti *cross-validation*, *GridSearchCV*, metrik evaluasi, dan sebagainya.
4) *Pipeline*, yaitu fitur yang berfungsi untuk menggabungkan beberapa langkah dalam proses *machine learning*, seperti *preprocessing* dan pelatihan model, menjadi satu objek yang mudah digunakan.
5) Integrasi, yaitu fitur yang berfungsi untuk menggabungkan dengan pustaka lain, seperti pandas, numpy, matplotlib, dan sebagainya.

BAB III
METODE PENELITIAN

1. Alur Penelitian

Penelitian ini berfokus pada membangun model deteksi serangan malware pada jaringan IoT berbasis *machine learning*. Secara umum, terdapat beberapa langkah untuk membangun model pada *machine learning*, yaitu persiapan data, pembersihan data, rekayasa fitur, serta analisa dan evaluasi data [24]. Langkah-langkah untuk membangun model deteksi serangan malware pada jaringan IoT digambarkan melalui alur penelitian pada Gambar 3.1. Model *machine learning* yang dibangun menggunakan software *jupyter notebook* dengan bahasa pemrograman python dan pustaka *scikit-learn*.

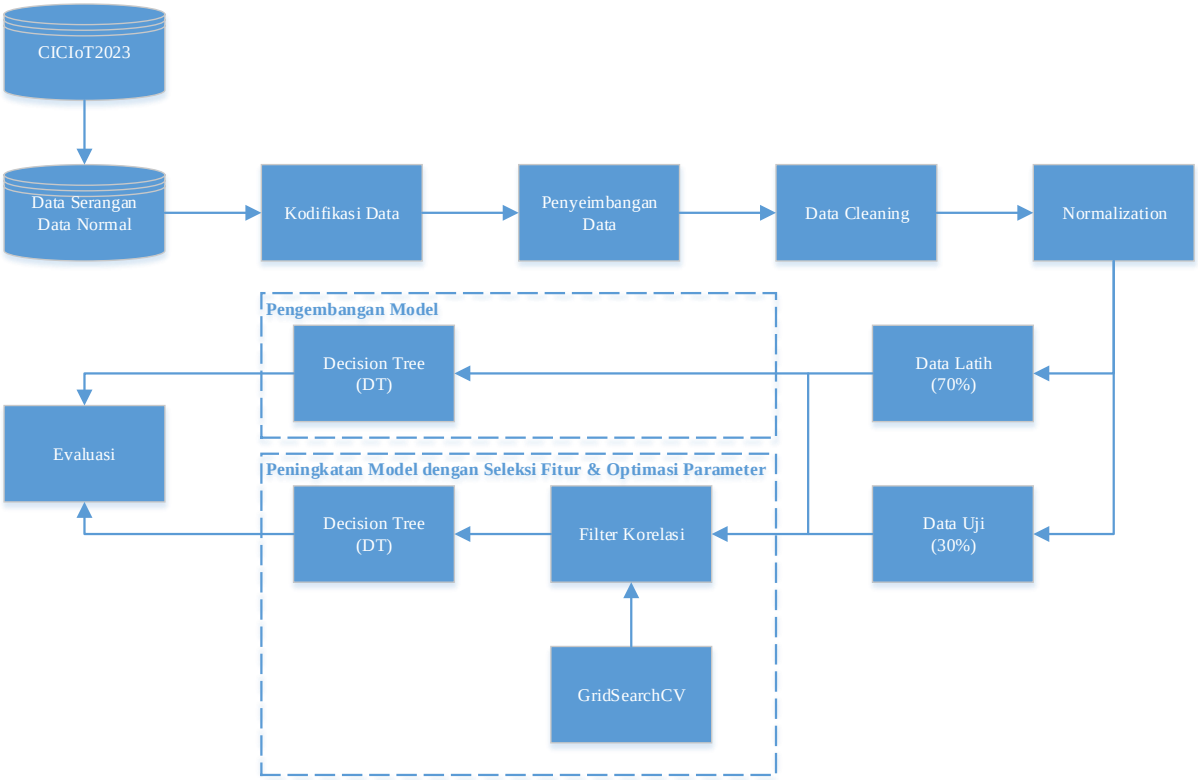

Gambar 3.1. Alur Penelitian Deteksi Serangan Malware pada Jaringan IoT

Pada Gambar 3.1., terdapat 2 skenario pengujian yang akan dilakukan pada penelitian ini, yaitu:

1) Skenario 1, yaitu pengembangan model deteksi serangan malware tanpa menggunakan teknik seleksi fitur dan optimasi parameter.
2) Skenario 2, yaitu peningkatan model deteksi serangan malware dengan menggunakan teknik seleksi fitur dan optimasi parameter.

2. Dataset Penelitian

Penelitian ini menggunakan dataset serangan malware yang terbaru dan telah divalidasi di dunia, yaitu CICIoT2023. CICIoT2023 merupakan dataset serangan pada jaringan IoT yang dihasilkan oleh University of New Brunswick dan tersedia secara terbuka [25]. Dataset ini terdiri dari 46.686.759 data yang dikelompokkan menjadi 7 jenis serangan, yaitu DDoS, DoS, Mirai, Benign, Spoofing, Recon, Web-based, dan Brute Force dengan rincian jumlah serangan ditunjukkan pada Tabel 3.1. [26]. Selain itu, dataset ini terdiri dari 46 fitur, seperti *flow duration, header length, protocol type*, dan sebagainya.

Tabel 3.1. Jumlah Serangan pada Dataset CICIoT2023

Label	Jumlah
DDoS	33.984.560
DoS	8.090.738
Mirai	2.634.124
Benign	1.098.195
Spoofing	486.504
Recon	354.565
Web-based	24.829
Brute Force	13.064
Total	46.686.579

Penelitian ini berfokus pada deteksi serangan malware sehingga kelas data yang digunakan adalah Mirai yang berjumlah 2.634.124 data sebagai data serangan dan Benign yang berjumlah 1.098.195 data sebagai data normal. Kemudian, dilakukan kodifikasi data dengan mengubah nama kelas data serangan menjadi ‘1’ dan nama kelas data normal menjadi ‘0’ untuk mempermudah proses analisis data. Berdasarkan sampel data tersebut, terdapat ketidakseimbangan jumlah data yang dapat menurunkan kualitas hasil model deteksi serangan malware. Oleh karena itu, dilakukan *Random Under Sampling* dengan mengurangi jumlah data mayoritas agar menjadi sama dengan jumlah data minoritas. Hasil

akhir dari tahap persiapan data ini adalah data sampel yang berisi data serangan dan data normal yang masing-masing berjumlah 1.098.195.

3. Pembersihan Data

Pembersihan Data dilakukan untuk memastikan bahwa tidak terdapat data yang kosong tidak valid. Kemudian, normalisasi data dilakukan agar skala data berada pada rentang yang sama, yaitu 0 – 1. Terakhir, pembagian data dilakukan dengan 70% untuk data latih dan 30% untuk data uji.

4. Parameter-Parameter pada Algoritma *Decision Tree*

Teknik optimasi parameter yang digunakan adalah *GridSearchCV* yang merupakan teknik untuk mencari kombinasi parameter-parameter yang menghasilkan kinerja algoritma *Decision Tree* yang optimal. Parameter-parameter *Decision Tree* yang dioptimasi pada penelitian ini yaitu:

1) '*criterion*', yaitu fungsi untuk mengukur kualitas split dengan rentang nilainya adalah '*gini*' dan '*entropy*',
2) '*max_depth*', yaitu kedalaman maksimum pohon dengan rentang nilainya adalah antara 2 sampai dengan 10,
3) '*min_samples_split*', yaitu jumlah sampel yang diperlukan untuk membagi node internal dengan rentang nilainya adalah antara 1 sampai dengan 5, dan
4) 'min_samples_leaf', yaitu jumlah sampel minimum yang diperlukan untuk berada pada simpul daun dengan rentang nilainya adalah antara 1 sampai dengan 5.

5. Evaluasi

Secara umum, evaluasi model klasifikasi pada *machine learning* dapat menggunakan *confusion matrix* seperti pada Tabel 3.2. sebagai berikut.

Tabel 3.2. Confusion Matrix

	Actual Positive	**Actual Negative**
Prediction Positive	True Positive (TP)	False Positive (FP)
Prediction Negative	False Negative (FN)	True Negative (TN)

1) Akurasi merupakan perbandingan antara jumlah sampel yang diprediksi benar dengan jumlah sampel keseluruhan.

$$\boldsymbol{Akurasi = \frac{TP + TN}{TP + TN + FP + FN}}$$

2) Presisi menunjukkan efektivitas model yang merupakan perbandingan antara jumlah serangan yang diprediksi benar dengan jumlah serangan yang diprediksi keseluruhan.

$$\boldsymbol{Presisi = \frac{TP}{TP + FP}}$$

3) *Recall* atau *Detection Rate* menunjukkan kemampuan model yang merupakan perbandingan antara jumlah serangan yang diprediksi benar dengan jumlah serangan yang sesungguhnya keseluruhan.

$$\boldsymbol{Recall = \frac{TP}{TP + FN}}$$

4) *F1* adalah kombinasi antara presisi dan *recall* yang menunjukkan kinerja model.

$$\boldsymbol{F1 = \frac{2\ x\ Presisi\ x\ Recall}{Presisi + Recall}}$$

5) Waktu komputasi adalah waktu yang digunakan untuk melatih dan menguji model.

$$\boldsymbol{waktu\ komputasi = waktu\ selesai\ pengujian - waktu\ mulai\ pelatihan}$$

DAFTAR PUSTAKA

[1] A. Al-Fuqaha, M. Guizani, M. Mohammadi, M. Aledhari, and M. Ayyash, "*Internet of Things: A Survey on Enabling Technologies, Protocols, and Applications*", IEEE Communications Surveys & Tutorials, vol. 17, no. 4, pp. 2347-2376, Fourth-Quarter 2015, doi: 10.1109/COMST.2015.2444095.

[2] J. Lin, W. Yu, N. Zhang, X. Yang, H. Zhang, and W. Zhao, "*A Survey on Internet of Things: Architecture, Enabling Technologies, Security and Privacy, and Applications*", IEEE Internet of Things Journal, vol. 4, no. 5, pp. 1125-1142, Oktober 2017, doi: 10.1109/JIOT.2017.2683200.

[3] N. Mishra and S. Pandya, "*Internet of Things Applications, Security Challenges, Attacks, Intrusion Detection, and Future Visions: A Systematic Review*", IEEE Access, vol. 9, pp. 59353-59377, 2021, doi: 10.1109/ACCESS.2021.3073408.

[4] Dange, Smita, and Madhumita Chatterjee. "*IoT Botnet: The Largest Threat to the IoT Network*", Data Communication and Networks: Proceedings of GUCON 2019. Singapura: Springer Singapore, 2019. 137-157.

[5] Yamaguchi, S., "*Botnet Defense System: Concept, Design, and Basic Strategy*", Information 2020, 11, 516. https://doi.org/10.3390/info11110516.

[6] Arifin, M. A. S., Susilo, A. A. T., Susanto, S., Martadinata, A. T., & Santoso, B, "Deteksi Aktifitas Malware pada Internet of Things menggunakan Algoritma Decision Tree dan Random Forest", *KLIK: Kajian Ilmiah Informatika dan Komputer*, 2024, 4(6), 3073-3079.

[7] Setiawan, D., Nugraha, A., & Luthfiarta, A., "Komparasi Teknik Feature Selection Dalam Klasifikasi Serangan IoT Menggunakan Algoritma Decision Tree", *Jurnal Media Informatika Budidarma*, 2024, 8(1), 83-93.

[8] Yu, T., & Zhu, H., "*Hyper-parameter optimization: A review of algorithms and applications*", 2020, arXiv preprint arXiv:2003.05689.

[9] K. Shafique, B. A. Khawaja, F. Sabir, S. Qazi, and M. Mustaqim, "*Internet of Things (IoT) for Next-Generation Smart Systems: A Review of Current Challenges, Future Trends and Prospects for Emerging 5G-IoT Scenarios*", IEEE Access, vol. 8, pp. 23022-23040, 2020, doi: 10.1109/ACCESS.2020.2970118.

[10] Geeks for Geeks, "*Architecture of Internet of Things*", 21 Juni 2024, [Online], tersedia: https://www.geeksforgeeks.org/architecture-of-internet-of-things-iot/ [diakses pada 20 November 2024].

[11] Maniriho P, Mahmood AN, Chowdhury MJ, "*A study on malicious software behaviour analysis and detection techniques: Taxonomy, current trends, and challenges*", Future Generation Computer Systems. 2022 May 1;130:1-8.

[12] Jordan, Michael I., and Tom M. Mitchell. "Machine learning: Trends, perspectives, and prospects". *Science* 349.6245 (2015): 255-260.

[13] Panagiotis (Panos) Papaemmanouil, "*Classical Programming vs. Machine Learning in plain English*", 18 Juni 2022, [Online], tersedia: https://medium.com/codex/classical-programming-vs-machine-learning-in-plain-english-3f39c56673d9 [diakses pada 28 November 2024].

[14] A. Binbusayyis and T. Vaiyapuri, "*Identifying and Benchmarking Key Features for Cyber Intrusion Detection: An Ensemble Approach*", IEEE Access, vol. 7, pp. 106495-106513, 2019, doi: 10.1109/ACCESS.2019.2929487.

[15] Song YY, Lu Y, "*Decision tree methods: applications for classification and prediction*", Shanghai Arch Psychiatry. 2015 Apr 25;27(2):130-5. doi: 10.11919/j.issn.1002-0829.215044.

[16] Trivusi, "*Decision Tree: Pengertian, Cara Kerja, Kelebihan, dan Kekurangannya*", 17 September 2022, [Online], tersedia: https://www.trivusi.web.id/2022/06/algoritma-decision-tree.html [diakses pada 20 November 2024].

[17] Zebari R, Abdulazeez A, Zeebaree D, Zebari D, Saeed J, "*A comprehensive review of dimensionality reduction techniques for feature selection and feature extraction*", Journal of Applied Science and Technology Trends. 2020 May 15;1(1):56-70.

[18] Guyon I. dan Elisseeff A., "*An introduction to variable and feature selection*", Journal of machine learning research. 2003;3(Mar):1157-82.

[19] Taylor, Richard, "*Interpretation of The Correlation Coefficient: A Basic Review*", Journal of Diagnostic Medical Sonography 6, No. 1 (1990): 35-39.

[20] Will Badr, "*Why Feature Correlation Matters ... A Lot*", Jan 18, 2019, [Online], tersedia: https://towardsdatascience.com/why-feature-correlation-matters-a-lot-847e8ba439c4 [diakses pada 20 November 2024].

[21] Bergstra J. dan Bengio Y., "*Random Search for Hyper-Parameter Optimization*", Journal of Machine Learning Research. 2012 Feb 1;13(2).

[22] Kohavi, R., "*A study of cross-validation and bootstrap for accuracy estimation and model selection*", Morgan Kaufman Publishing (1995).

[23] https://scikit-learn.org/stable/index.html

[24] Wirth R., Hipp J., "*CRISP-DM: Towards a standard process model for data mining*", Proceedings of the 4th International Conference on The Practical Applications of Knowledge Discovery and Data Mining, 2000 Apr 11 (vol. 1, pp. 29-39).

[25] https://www.unb.ca/cic/datasets/iotdataset-2023.html

[26] Neto, E.C.P.; Dadkhah, S.; Ferreira R.; Zohourian, A.; Lu, R.; Ghorbani, A.A., "*CICIoT2023: A Real-Time Dataset and Benchmark for Large-Scale Attacks in IoT Environment*", Sensors 2023, 23, 5941. https://doi.org/10.3390/s23135941.